

AIGC检测 · 简洁报告单

NO:CNKIAIGC2026SJ_202605130126692

检测时间: 2026-05-14 16:43:08


篇名: 基于CNN与YuNet的人脸表情识别系统设计与实现

作者: 张吉鹏

单位:

文件名: 1356339_张吉鹏_基于CNN与YuNet的人脸表情识别系统设计与实现.docx

全文检测结果



AI特征值: 26.4%

AI特征字符数: 8615

总字符数: 32580

- AI特征显著 (计入AI特征字符数)
- AI特征疑似 (未计入AI特征字符数)
- 未标识部分

AIGC片段分布图

前部20%

AI特征值: 6.2%

AI特征字符数: 405

中部60%

AI特征值: 37.0%

AI特征字符数: 7229

后部20%

AI特征值: 15.1%

AI特征字符数: 981



分段检测结果

序号	AI特征值	AI特征字符数 / 章节(部分)字符数	章节(部分)名称
1	11.1%	405 / 3645	中英文摘要等
2	12.7%	537 / 4243	第1章绪论
3	87.4%	5285 / 6050	第2章系统需求分析与架构设计
4	16.6%	1025 / 6189	第3章表情识别模型构建与训练

5	9.7%	382 / 3955	第4章模型训练优化
6	10.7%	670 / 6273	第5章系统实现与运行测试
7	14.0%	311 / 2225	第6章结论与展望

1. 中英文摘要等

AI特征值: 11.1%AI特征字符数 / 章节(部分)字符数: 405 / 3645

片段指标列表

序号	片段名称	字符数		
1	片段1	405		11.1%

片段详情

NO.1 片段1 字符数: 405 AI特征: 显著 11.1%

No program crash, camera interruption, or interface freeze is observed during continuous operation. These results indicate that the system completes the full workflow from model training to edge deployment and has practical real-time performance, stability, and engineering value.
Key Words: facial expression recognition; convolutional neural network; YuNet; MobileNetV3; Raspberry Pi; edge deployment

2. 第1章绪论

AI特征值: 12.7%AI特征字符数 / 章节(部分)字符数: 537 / 4243

片段指标列表

序号	片段名称	字符数		
2	片段1	537		12.7%

片段详情

1.4 本文结构安排

本文共分为六章，各章内容安排如下。

第1章为绪论。主要介绍人脸表情识别的研究背景与意义，梳理传统方法、深度学习方法、轻量化网络和端侧部署相关研究现状，并说明本文的主要研究内容和结构安排。

第2章为系统需求分析与架构设计。主要分析端侧人脸表情识别系统的应用场景、功能需求和性能需求，设计系统总体架构，并对图像采集、人脸检测、表情分类和结果输出等模块进行划分。

第3章为表情识别模型构建与训练。主要介绍数据集构建与预处理方法，说明MobileNetV3表情分类网络的结构调整过程，并对数据增强、类别均衡和训练配置等内容进行说明。

第4章为模型训练优化与实验结果分析。主要围绕模型训练过程展开，分析基础监督训练、多阶段训练和伪标签辅助优化对模型效果的影响，并通过准确率、宏平均F1值和混淆矩阵等指标评价最终模型性能。

第5章为系统实现、模型部署与运行测试。主要介绍模型导出与转换流程、树莓派端推理程序设计、摄像头实时识别流程集成，以及系统功能、实时性和稳定性测试结果，重点验证系统在端侧平台上的实际运行效果。

第6章为结论与展望。主要总结本文完成的工作，分析系统当前存在的不足，并从模型优化、多场景适应性和端侧部署性能等方面提出后续改进方向。

3. 第2章系统需求分析与架构设计

AI特征值：87.4%

AI特征字符数 / 章节(部分)字符数：5285 / 6050

片段指标列表

序号	片段名称	字符数		
3	片段1	1541		25.5%
4	片段2	2955		48.8%
5	片段3	789		13.0%

片段详情

2.1.1 应用场景与任务目标

本文系统主要面向室内近距离人机交互场景，例如课堂状态观察、智能终端交互演示和情绪识别原型系统验证等。在这类场景中，摄像头通常固定在桌面、显示器或嵌入式设备附近，用户与摄像头之间保持相对稳定的距离，环境光照和背景变化也相对有限。基于这一使用条件，本文不将远距离监控、多角度遮挡和复杂多人场景作为主要研究对象，而是重点验证单人或少量人脸情况下的端侧实时识别流程。

系统识别对象为人脸图像中的七类基本表情，包括愤怒、厌恶、恐惧、高兴、悲伤、惊讶和中性。系统运行时，摄像头连续采集图像帧，YuNet模型从图像中检测人脸位置，程序根据检测框截取人脸区域，并将其调整为分类模型所需的输入尺寸。随后，MobileNetV3表情分类模型输出各类别概率，系统选取概率最高的类别作为当前表情识别结果。

从任务目标上看，本文并不以提出新的复杂网络结构为重点，而是围绕“模型训练—模型转换—部署—实时测试”这一完整流程展开。也就是说，本文不仅关注模型在测试集上的准确率，还关注模型能否在树莓派端稳定运行，并通过摄像头画面直观展示识别结果。

2.1.2 功能需求分析

根据系统任务目标，本文系统主要包括以下功能。

第一，视频采集功能。系统需要调用摄像头获取实时画面，并将读取到的图像帧送入后续处理流程。由于实时识别对画面连续性要求较高，摄像头读取过程不能长时间阻塞主循环，否则会造成显示延迟或画面卡顿。因此，视频采集模块需要保证输入画面稳定，并尽量减少对检测和分类过程的影响。

第二，人脸检测功能。系统需要在视频帧中定位人脸区域，并输出人脸检测框和关键点信息。本文选用YuNet作为前端检测模型，主要原因是该模型体积较小、调用方便，适合嵌入式端侧系统集成。检测结果直接决定后续裁剪区域的质量，如果人脸框偏移较大，分类模型接收到的图像可能缺少有效表情信息，因此检测模块需要兼顾速度和定位稳定性。

第三，图像预处理功能。系统根据检测框裁剪人脸区域后，需要对图像进行尺寸缩放、颜色通道转换和归一化处理，使端侧输入格式与训练阶段保持一致。本文表情分类模型输入尺寸为 224×224 ，训练和推理阶段均采用相同的归一化方式，以减少模型转换后输入分布不一致带来的影响。

第四，表情分类功能。系统将预处理后的人脸图像输入MobileNetV3分类模型，得到七类表情的预测概率。程序根据最大概率确定表情类别，并结合置信度显示识别结果。考虑到实际摄像头画面中可能存在表情不明显、姿态变化或光照不均等情况，系统输出结果时保留置信度信息，便于观察模型判断是否稳定。

第五，结果显示功能。系统需要在实时画面中绘制人脸框，并在框附近显示表情类别和置信度。同时，为了便于调试和测试，界面中还可以显示帧率、检测耗时和分类耗时等信息。这样既能展示识别效果，也能辅助判断系统运行瓶颈。

第六，结果保存与调试功能。系统应能够保存部分识别画面或测试结果，用于后续分析和毕业设计。

计展示。该功能不属于识别流程的核心环节，但有助于记录不同表情类别下的运行效果，也方便在系统测试中检查误识别情况。

2.1.3 性能需求分析

端侧人脸表情识别系统除了功能完整外，还需要满足一定的性能要求。由于树莓派平台的计算资源有限，系统设计不能只追求离线测试准确率，还需要综合考虑模型规模、推理速度和连续运行稳定性。

首先，系统需要具备基本识别准确率。表情分类模型应能够在测试集上取得较稳定的准确率和宏平均F1值，并且在摄像头实际画面中能够对常见表情作出合理判断。由于不同表情之间存在相似性，部分样本还会受到光照、姿态和个体差异影响，因此模型评价时不能只看整体准确率，还需要结合混淆矩阵和各类别表现进行分析。

NO.4 片段2 字符数: 2955 AI特征: 显著  48.8%

再次，系统需要控制资源占用。表情分类模型需要在端侧设备上完成推理，因此模型结构不宜过大。本文选用MobileNetV3作为分类骨干，并在部署阶段将模型转换为TensorFlow Lite格式，以便在树莓派端加载运行。与直接使用PC端训练模型相比，转换后的端侧模型更适合嵌入式运行环境。

最后，系统需要具备连续运行稳定性。系统测试过程中应能够持续完成摄像头读取、人脸检测、表情分类和结果显示，避免出现摄像头中断、界面卡死或程序异常退出等问题。稳定性不仅取决于模型大小，也与摄像头读取方式、检测频率、推理线程数和结果显示流程有关。因此，本文在系统实现与测试阶段对这些因素进行综合调整。

2.2 系统总体架构设计

2.2.1 系统总体架构概述

根据上述需求，本文采用分层设计思路构建端侧人脸表情识别系统。系统整体技术路线如图2-1所示，主要包括硬件层、数据层、模型训练与伪标签生成层、模型评估与分析层以及在线推理与应用层。各层按照“数据准备—模型训练—模型评价—模型转换—端侧运行”的顺序衔接，最终形成从离线训练到树莓派实时识别的完整流程。

图 2-1 端侧人脸表情识别系统总体技术路线图

硬件层主要包括PC训练平台、Raspberry Pi 5和摄像头设备。PC端用于完成数据整理、模型训练和模型导出；树莓派端用于加载转换后的模型，并运行摄像头实时识别程序；摄像头负责采集输入画面，为系统提供连续图像帧。

数据层主要包括有标签数据、无标签数据和伪标签数据。有标签数据用于基础监督训练和模型评估，无标签数据用于伪标签生成，筛选后的伪标签数据则作为后续训练优化的补充样本。通过这种方式，系统能够在已有标注数据基础上进一步利用无标签样本，提高训练数据的利用率。

模型训练与伪标签生成层包括基础监督训练、伪标签生成和多阶段训练三个部分。首先，系统利用有标签样本训练初始分类模型；然后使用训练后的模型对无标签数据进行推理，筛选置信度较高

的样本生成伪标签；最后，将真实标注样本与伪标签样本结合，用于后续模型优化。

模型评估与分析层主要负责验证模型效果。本文通过准确率、宏平均F1值和混淆矩阵等指标评价模型性能，判断模型是否满足部署要求。该部分结果也为第4章的训练优化分析提供依据。

在线推理与应用层是系统最终运行部分。摄像头采集图像后，系统先调用YuNet进行人脸检测，再对人脸区域进行裁剪和预处理，随后输入MobileNetV3表情分类模型，最后将识别结果绘制在实时画面中。该层体现了本文从算法训练到端侧应用的工程闭环。

2.2.2 系统识别流程设计

为了说明树莓派端程序的运行过程，本文对实时识别流程进行设计，如图2-2所示。该流程主要包括系统初始化、视频帧读取、人脸检测、人脸裁剪与预处理、表情分类、结果显示与保存等步骤。

图 2-2 系统识别流程图

系统启动后，首先加载YuNet人脸检测模型和TensorFlow Lite表情分类模型，同时初始化摄像头、类别标签和显示窗口。如果摄像头无法正常打开，程序需要及时提示异常，避免进入无效循环。

完成初始化后，系统从摄像头读取当前帧。对于读取成功的图像，程序先进行必要的尺寸处理，再送入人脸检测模块。若当前帧未检测到人脸，则直接显示画面并等待下一帧；若检测到人脸，则根据检测框进入后续处理流程。

在人脸裁剪阶段，程序会对检测框进行边界检查，并适当扩展人脸区域，使裁剪图像尽量包含完整面部信息。裁剪后的人脸图像被缩放到 224×224 ，并完成通道转换和归一化处理。该步骤需要与训练阶段保持一致，否则可能影响分类模型输出。

表情分类阶段将预处理后的人脸图像输入TFLite模型，得到七类表情概率。系统取最大概率对应类别作为识别结果，并记录该类别的置信度。最后，程序在实时画面中绘制人脸框、关键点、表情类别和置信度，同时根据设定条件保存部分识别画面，用于后续实验分析和效果展示。

2.2.3 系统功能模块划分

结合系统架构和识别流程，本文将端侧人脸表情识别系统划分为五个功能模块。

1. 图像采集模块

图像采集模块负责从摄像头读取实时视频帧，是系统输入端。该模块需要保证画面读取连续，并将图像传递给后续检测流程。在树莓派端运行时，摄像头读取速度会影响整体流畅度，因此程序设计时需要尽量减少帧读取阻塞。

2. 人脸检测模块

人脸检测模块负责在视频帧中定位人脸区域。本文采用 YuNet 输出人脸检测框和关键点信息，为后续人脸裁剪提供依据。该模块既要保证检测结果可用，也要控制检测耗时，避免影响实时显示。

3. 图像预处理模块

图像预处理模块负责将检测到的人脸区域转换为分类模型可接受的输入格式，主要包括人脸裁剪

、边界修正、尺寸缩放、颜色转换和归一化处理。预处理结果需要与训练阶段输入保持一致，这是保证模型部署效果的重要条件。

4. 表情识别模块

表情识别模块负责对人脸图像进行七类表情分类。本文使用 MobileNetV3 作为分类骨干网络，并将最终输出层调整为七类表情。该模块输出表情类别和预测置信度，是系统识别结果的主要来源。

5. 结果输出与管理模块

结果输出与管理模块负责将识别结果展示给用户，包括绘制人脸框、关键点、表情类别、置信度和运行状态信息。同时，该模块根据需保存部分识别画面，便于后续整理实验结果和展示系统运行效果。

2.3 关键技术与方法选型

本节对系统中使用的关键技术进行选型说明。第2章只从系统设计角度说明技术选择理由，具体模型结构、训练参数、实验结果和部署细节将在第3章至第5章中进一步展开。

2.3.1 人脸检测模型选型

人脸检测是表情识别系统的前置环节，其检测结果会直接影响后续分类效果。如果检测框偏移较大，人脸区域可能缺少关键表情信息；如果检测耗时过长，系统整体帧率会下降。因此，检测模型需要在精度、速度和部署便利性之间取得平衡。

本文选用YuNet作为人脸检测模型。YuNet是一种轻量级人脸检测模型，能够输出人脸框和关键点信息，如图2-3所示，适合在边缘设备或实时应用中使用。与较复杂的人脸检测网络相比，YuNet更便于在OpenCV环境下调用，也更符合树莓派端系统对轻量化和实时性的要求[10]。

在本文系统中，YuNet主要用于摄像头画面中的人脸定位。为了减少树莓派端的计算压力，部署阶段可通过缩小检测输入尺寸、设置检测间隔等方式降低检测负载。这样既能维持检测结果的连续性，又能避免检测模块占用过多时间。

图 2-3 YuNet人脸检测示意图

2.3.2 表情分类模型选型

表情分类模型需要对裁剪后的人脸图像进行七类表情判断。考虑到系统最终部署在树莓派端，分类模型不能过于复杂，否则会增加推理延迟和内存占用。与此同时，模型仍需要具备一定的特征提取能力，以区分相似表情类别。

MobileNetV3是一种面向移动端和资源受限设备设计的轻量化卷积神经网络。该网络通过深度可分离卷积、倒残差结构和轻量化注意力模块减少计算量，同时保持较好的特征表达能力[9]，如图2-4所示。因此，本文选用MobileNetV3作为表情分类模型骨干网络，并将最终分类层调整为七类输出。

图 2-4 MobileNetV3网络结构示意图

2.3.3 训练优化方法选型

表情识别模型的效果不仅取决于网络结构，也与数据质量和训练策略有关。FER2013 类数据中不同类别样本数量存在差异，部分类别之间表情边界也较模糊，容易造成模型对少数类识别不足或对相似类别产生混淆。因此，训练阶段需要采用一定的优化方法提升模型稳定性。

本文训练阶段主要采用数据增强、类别均衡、伪标签筛选和多阶段训练等策略。数据增强用于增加样本变化，提高模型对姿态、光照和局部扰动的适应能力；类别均衡用于减弱样本数量差异对训练过程的影响；伪标签方法则用于利用无标签样本，为后续训练提供补充监督信息。

需要说明的是，本文并不将伪标签方法作为核心理论创新点，而是将其作为训练优化手段。系统首先利用有标签数据训练基础模型，再通过模型对无标签数据进行预测，筛选高置信度样本生成伪标签，最后将伪标签样本与真实标注样本结合进行后续训练。该流程有助于扩充训练数据，但其效果仍需要通过验证集和测试集结果进行判断。

2.4 本章小结

本章围绕端侧人脸表情识别系统的需求分析与架构设计展开说明。首先，结合室内近距离识别场景，明确了系统需要完成视频采集、人脸检测、人脸裁剪、表情分类、结果显示和图像保存等功能，并从准确率、实时性、资源占用和稳定性等方面分析了系统性能需求。

其次，本文设计了从数据准备、模型训练、模型评估到树莓派端部署运行的总体架构，并对系统实时识别流程进行了说明。该流程以摄像头图像为输入，依次完成人脸检测、图像预处理、表情分类和结果输出，体现了本文从离线模型训练到端侧实时应用的完整过程。

最后，本章对YuNet人脸检测模型、MobileNetV3表情分类模型和训练优化方法进行了选型说明。下一章将进一步围绕表情分类模型展开，重点介绍数据集构建、预处理方法、模型结构调整和训练策略设计。

4. 第3章表情识别模型构建与训练

AI特征值: 16.6% AI特征字符数 / 章节(部分)字符数: 1025 / 6189

片段指标列表

序号	片段名称	字符数		
6	片段1	458		7.4%
7	片段2	542		8.8%
8	片段3	271		4.4%
9	片段4	483		7.8%

NO.6

片段1

字符数: 458

AI特征: 疑似

7.4%

为缓解这一问题，本文在原始数据基础上补充了扩展样本，并对数据进行统一整理。扩充后数据集总量达到410246张。为了直观展示扩充前后的变化，本文绘制了原始FER2013数据集与扩充后数据集的类别数量对比图，如图3-1所示。

图 3-1 原始FER2013与扩充后数据集类别数量对比

由图3-1可以看出，扩充后各类样本数量均有所增加。其中，原始数据中较少的厌恶类和恐惧类分别增加至17128张和16954张，数据稀缺问题得到一定缓解。与此同时，高兴类和中性类仍然是样本数量较多的类别，说明扩充后的数据集仍存在类别不均衡现象。因此，后续训练中仍需要引入类别均衡策略，避免模型过度偏向多数类别。

3.1.2 CSV数据合并与数据集划分

本文训练过程中没有直接采用文件夹路径读取方式，而是将原始样本和扩展样本统一转换为CSV格式进行管理。每条CSV记录主要包括类别标签和图像像素信息，部分扩展样本也可通过图像路径字段读取。这样处理后，不同来源的数据可以通过统一的数据加载脚本读取，减少了训练阶段对样本来源的额外判断。

NO.7

片段2

字符数: 542

AI特征: 显著

8.8%

3.1.3 数据预处理与增强策略

由于MobileNetV3模型要求固定尺寸输入，本文在训练前需要对CSV中的图像数据进行还原和预处理。对于FER2013格式样本，训练脚本先将像素序列还原为48×48灰度图，再转换为三通道图像，以适配基于ImageNet预训练权重的MobileNetV3模型。随后，所有输入图像统一调整为224×224像素。

在归一化处理方面，本文采用ImageNet数据集常用的均值和标准差进行标准化处理。这样设置主要是为了与预训练模型的输入分布保持一致，减少从ImageNet预训练模型迁移到表情识别任务时的输入差异。

训练阶段采用适度数据增强，以提高模型对人脸姿态变化、轻微旋转和局部遮挡的适应能力。具体包括随机水平翻转、随机旋转、随机裁剪缩放和随机擦除等操作。其中，随机水平翻转用于模拟左右姿态变化；随机旋转用于模拟头部轻微偏转；随机裁剪缩放用于增强模型对人脸边界变化的容忍度；随机擦除则用于模拟局部遮挡情况。

验证集和测试集不使用随机增强，只进行尺寸调整和归一化处理。这样可以保证评估阶段输入稳定，避免随机增强对评价结果造成干扰。通过上述预处理方式，训练阶段能够提供更多样的输入变化，而评估阶段则保持统一的测试条件。

针对这一问题，本文在训练阶段引入类别均衡策略。训练脚本会统计训练集中各类别样本数量，并根据类别分布计算类别权重。样本数量较少的类别在损失函数中获得相对较高权重，样本数量较多的类别权重相对降低，从而减弱类别数量差异对模型训练的影响。

此外，本文在基础训练阶段还设置了每类样本数量上限，用于控制单轮训练中多数类样本的占比。这样可以在保证训练样本规模的同时，减少多数类样本对训练过程的过度主导。类别均衡策略并不能完全消除类别间混淆，但可以提升训练过程对少数类别的关注度。

3.2 模型架构设计

3.2.1 MobileNetV3骨干网络选型

在模型保存方面，训练过程以验证集宏平均F1值作为最优模型判断依据。当验证集宏平均F1值提升时，保存当前模型；如果连续多轮没有提升，则触发早停机制。该策略可以避免训练后期过拟合，同时保证最终保存模型具有较好的综合分类能力。

3.4 本章小结

本章围绕表情分类模型的构建与训练方案进行了说明。首先，介绍了数据集来源、扩充过程和CSV格式整理方式，并将扩充后数据集划分为训练集、验证集、测试集和无标签集，为后续监督训练和伪标签辅助训练提供数据基础。

其次，本章说明了图像预处理和数据增强方法。训练阶段采用随机翻转、随机旋转、随机裁剪缩放和随机擦除等操作，以提升模型对姿态变化和局部遮挡的适应能力；验证集和测试集只进行尺寸调整和归一化处理，以保证评价过程稳定。

最后，本章完成了MobileNetV3表情分类模型设计和训练策略说明。模型以MobileNetV3-large为骨干网络，将分类层调整为七类输出，并采用类别均衡、标签平滑、学习率调度、早停和伪标签辅助训练等方法提高训练稳定性。下一章将基于本章设计的训练流程，对不同阶段的训练结果和最终模型表现进行分析。

5. 第4章模型训练优化

AI特征值: 9.7% AI特征字符数 / 章节(部分)字符数: 382 / 3955

片段指标列表

序号	片段名称	字符数
----	------	-----

10	片段1	367		9.3%
11	片段2	382		9.7%

片段详情

NO.10

片段1

字符数：367

AI特征：疑似

9.3%

其中，伪标签辅助训练的作用是补充可利用样本信息，提高无标签数据的利用效率，但模型最终效果仍需通过验证集、测试集和混淆矩阵等结果进行综合评价。模型最终效果仍需通过验证集、测试集和混淆矩阵等结果进行综合评价。为了避免与第3章内容重复，本章不再展开训练参数和数据增强细节，而重点分析多阶段训练结果、最终模型评价结果以及各类别识别表现。

4.2 多阶段训练结果对比

为比较不同训练阶段对模型性能的影响，本文分别对Stage 1、Stage 2和Stage 3阶段保存的最优模型进行统一评估。评估时采用验证集和测试集作为评价数据，并统计准确率和宏平均F1值。其中，准确率反映模型总体分类正确比例，宏平均F1值能够更好地反映类别不均衡场景下模型对各类表情的综合识别能力。

多阶段训练结果如表4-1所示。

表4-1 多阶段模型评价结果对比

NO.11

片段2

字符数：382

AI特征：显著

9.7%

由表4-3可以看出，高兴类的识别效果最好，其Precision、Recall和F1值分别为97.05%、95.54%和96.29%。这说明高兴表情的视觉特征较明显，例如嘴角上扬、面部肌肉变化较突出，模型较容易学习到该类表情的判别特征。中性类的F1值为90.47%，召回率达到93.02%，说明模型对中性表情也具有较好的识别能力。惊讶类F1值为89.56%，整体表现同样较稳定。

相比之下，恐惧类、悲伤类和厌恶类的F1值相对较低。其中，恐惧类F1值为81.77%，是七类表情中最低的一类；悲伤类F1值为82.73%，厌恶类F1值为83.87%。这说明这些类别在视觉表现上更容易与其他类别产生混淆。例如，恐惧表情在面部局部特征上可能与惊讶、悲伤或中性存在相似性；悲伤表情在表情强度较弱时容易接近中性；厌恶类样本数量相对较少，且面部表现差异较大，因此识别难度也较高。

6. 第5章系统实现与运行测试

AI特征值：10.7%

AI特征字符数 / 章节(部分)字符数：670 / 6273

片段指标列表

序号	片段名称	字符数		
12	片段1	336		5.4%
13	片段2	670		10.7%

片段详情

NO.12

片段1

字符数：336

AI特征：疑似

5.4%

在整体实现上，PC端主要承担模型训练、模型导出和格式转换任务；树莓派端主要承担视频采集、人脸检测、表情分类、结果显示和图像保存任务。通过这种方式，本文完成了从模型训练、模型转换到树莓派端运行验证的完整闭环。本章重点通过模型导出文件、端侧推理参数和实际运行截图说明系统实现过程。

5.2 软件环境与硬件平台配置

5.2.1 硬件平台配置

本文系统涉及PC端训练转换平台和树莓派端部署平台。PC端用于数据处理、模型训练、模型评估和模型格式转换；树莓派端用于部署TFLite模型并完成实时识别测试。

硬件平台配置如表5-1所示。

表5-1 硬件平台配置

平台配置项具体信息

PC端训练与转换平台处理器 Intel Core i7-10870H @ 2.20GHz

NO.13

片段2

字符数：670

AI特征：显著

10.7%

从表5-6可以看出，系统在室内测试环境下能够保持较连续的画面显示，检测框和识别类别能够随人脸状态变化进行更新。YuNet检测耗时较低，主要得益于检测输入尺寸被降低至256×192以及间隔检测策略。分类耗时相对检测耗时更高，说明TFLite表情分类仍然是树莓派端主要计算开销之一。

5.5.3 运行效果展示

为了展示系统实际运行效果，本文选取了若干树莓派端运行截图，覆盖愤怒、恐惧、高兴、中性、悲伤等单人表情识别场景，以及少量多人识别场景。运行效果如图5-1和图5-2所示。

图5-1 单人场景下多类别表情识别效果

图5-1展示了单人场景下的多类别表情识别效果。可以看出，系统能够在画面中绘制人脸检测框和五点关键点，并在检测框附近显示目标编号、预测类别和置信度。画面左上角同时显示FPS、延迟

、检测耗时、分类耗时和主循环耗时等信息，便于观察系统实时运行状态。

图5-2 多人场景下表情识别效果

图5-2展示了多人场景下的识别效果。当画面中出现两个人脸时，系统能够检测并绘制多个人脸框。由于程序设置了max_infer_faces=1，系统优先对主要目标进行表情分类，以降低多人场景下的分类推理负载。因此，当前系统更适合单人近距离实时识别场景，在多人场景下仍需要进一步优化多目标分类策略。

5.5.4 稳定性测试

为验证系统连续运行能力，本文在树莓派端对系统进行了稳定性观察。测试过程中，系统持续执行摄像头读取、人脸检测、表情分类、结果显示和图像保存等操作，观察程序是否出现崩溃、摄像头中断、界面卡死或结果无法更新等异常情况。

7. 第6章结论与展望

AI特征值: 14.0% AI特征字符数 / 章节(部分)字符数: 311 / 2225

片段指标列表

序号	片段名称	字符数		
14	片段1	363		16.3%
15	片段2	311		14.0%

片段详情

NO.14

片段1

字符数: 363

AI特征: 疑似

16.3%

第三，端侧性能测试还可以进一步完善。本文实时性结果主要来自运行界面观察，虽然能够反映系统基本运行状态，但还缺少长时间自动化日志统计。后续可以在程序中加入性能记录模块，持续统计FPS、检测耗时、分类耗时、CPU占用率和内存占用情况，从而更准确地评估系统在不同场景下的运行表现。

第四，系统还可以进一步优化部署方式。当前模型采用FP16 TFLite格式运行，后续可以继续尝试INT8量化、模型剪枝或硬件加速推理方式，以进一步降低模型体积和推理耗时。同时，也可以针对树莓派端运行环境优化摄像头读取、显示刷新和图像保存逻辑，提高系统整体稳定性和响应速度。

综上，本文系统已经完成端侧人脸表情识别的基本设计与实现，后续可从数据质量、模型结构、多目标识别和端侧性能优化等方面继续改进，使系统在更复杂的实际场景中具有更好的适应能力。

其次,感谢学院各位老师在本科阶段对我的培养。通过四年的课程学习和实践训练,我逐步掌握了人工智能、计算机视觉、程序设计和系统开发等方面的基础知识,也为本次毕业设计的完成奠定了重要基础。

同时,感谢同学和朋友们在毕业设计过程中给予的帮助与鼓励。在系统调试、模型训练、资料整理和毕业设计修改过程中,他们的交流与建议帮助我更好地理清思路,也让我在遇到困难时能够保持信心。

最后,感谢我的家人一直以来的理解、支持和陪伴。正是他们在学习和生活中的鼓励,使我能够顺利完成本科阶段的学习任务。

本次毕业设计仍有许多不足之处,但它也是我本科阶段一次重要的综合实践。今后我将继续保持学习和探索的态度,不断提升自己的专业能力和实践能力。

说明:

- 1、支持中、英文内容检测;
- 2、 $\text{AI特征值} = \text{AI特征字符数} / \text{总字符数}$;
- 3、红色代表AI特征显著部分,计入AI特征字符数;
- 4、棕色代表AI特征疑似部分,未计入AI特征字符数;
- 5、检测结果仅供参考,最终判定是否存在学术不端行为时,需结合人工复核、机构审查以及具体学术政策的综合应用进行审慎判断。



关注微信公众号

知网AIGC检测服务